DAOWOO
达 沃 时 代

PDB数据同步与数据库设计学习分享

2016.07.14

涂仲秋

目录

- PDB(Paxos Data Base)模块概述
- PDB模块架构设计和系统组成
- PDB模块数据同步过程
- PDB模块数据库设计

PDB(Paxos Data Base)模块概述

DAOWOO 达沃时代

- 系统功能
  - PDB是一个分布式数据库，由一个集群组成，集群中的每个节点保存数据库的一个完整副本，为分布式应用提供协调服务(Coordination Service)：
    - 配置信息管理和维护(maintain configuration information)
    - 进程运行信息管理和维护
    - 组管理
    - 实现同步原语(synchronization primitive)
    - 节点失效恢复管理

- 系统性能
  - 高可用(High Availability)
  - 高可靠(High Reliability)
  - 高吞吐率
  - 读操作高性能
  - 容灾容错（2n+1个节点的集群，最多可容忍n个节点失效，集群节点数目最好为奇数个）

PDB模块架构设计和系统组成

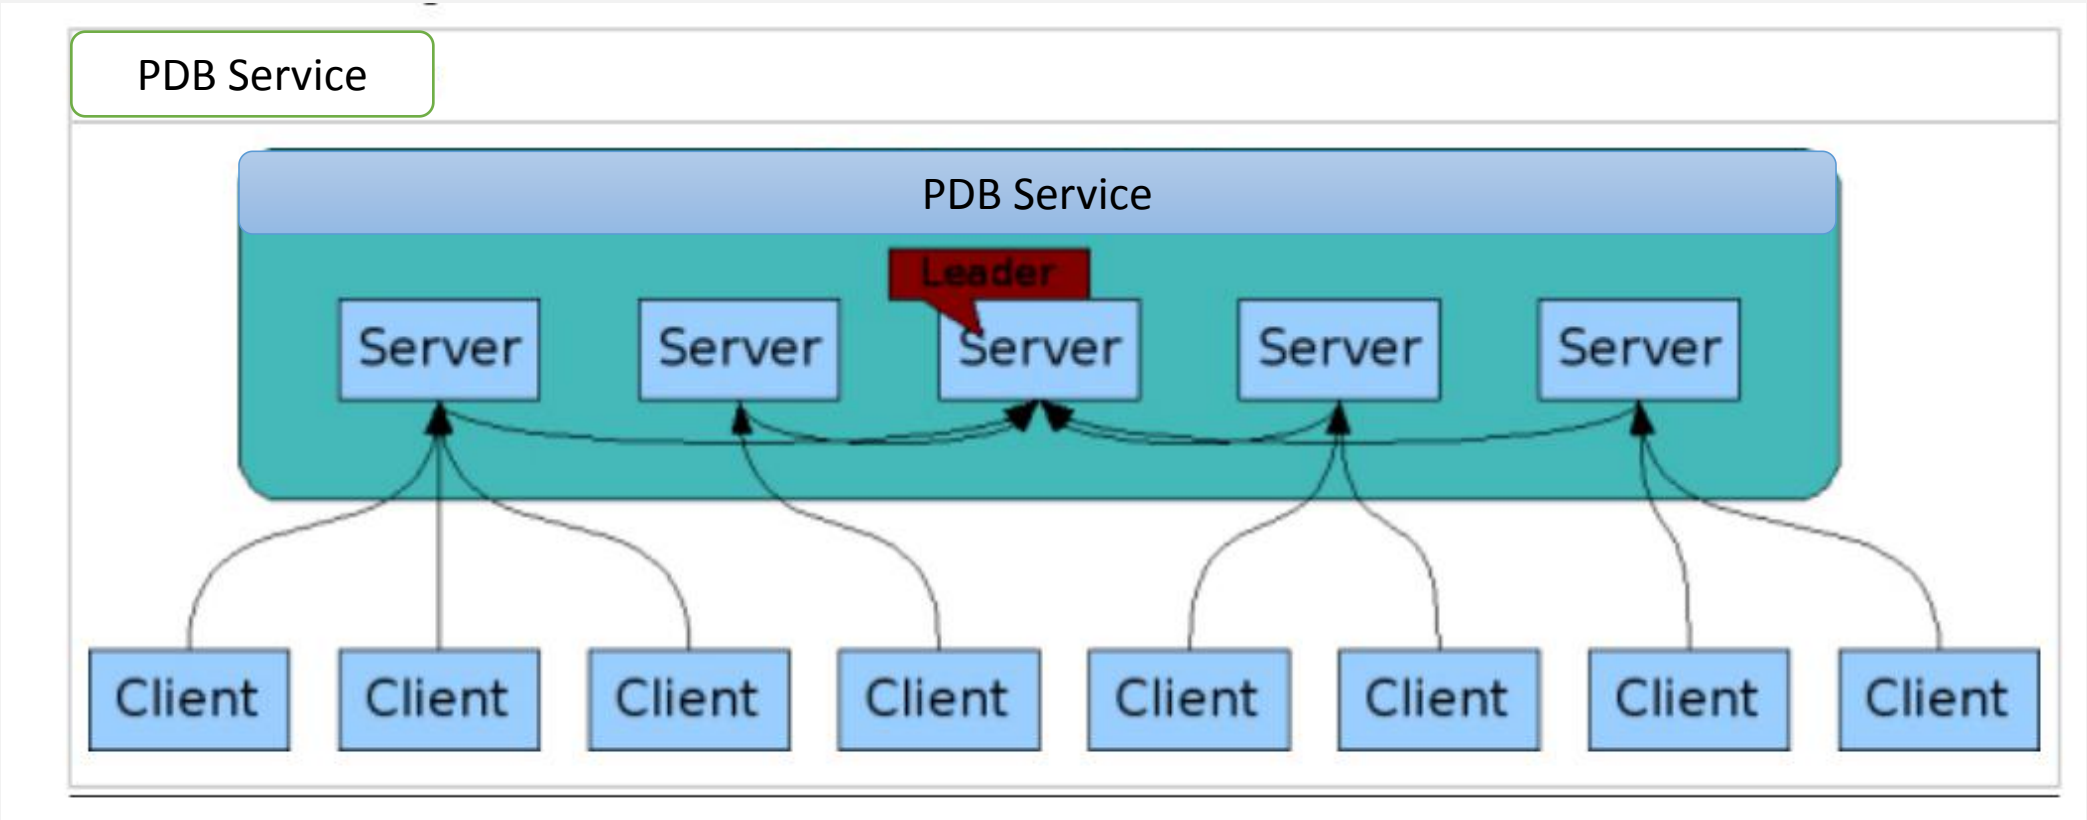

- Leader：系统中的主进程(Primary Process)，通过选举算法选出，除选举阶段外，系统中任何时刻有且仅有一个Leader节点。处理来自客户端的写请求，主导集群的数据同步。
- Follower：系统集群中除Leader外的任何节点都是Follower节点，跟随Leader节点做数据同步，与Leader的数据库保持一致。
- Client：连接到集群的客户端，可以与集群中任意一个节点建立连接，向系统发出读写请求。

PDB系统核心概念

DAOWOO 达沃时代

- 事务（Transaction）
  - 是数据库管理系统执行过程中的一个逻辑单位，由一个有限的数据库操作序列构成。
  - 客户端对PDB数据库的一个写操作，表示数据库的状态要发生变化，由主进程(Leader)产生，并广播到Follower节点。系统每收到一个写请求，就会产生一个事务。
- 事务ID（Transaction ID）
  - 每个事务的全局唯一编号，由Leader节点产生，用以区分各个不同事务，事务ID以递增的方式生成，用以标识各个事务产生的先后顺序，事务ID越大，表示事务越新。
- 事务日志（Transaction Log）
  - 记录每个事务内容、事务编号等信息的日志，Leader产生一个事务后会将事务日志持久化记录到本地，用于数据同步。
- Epoch
  - 字面意思为时期、时代、纪元。用以表示某个Leader节点管理集群的时期，每次发生Leader选举后，新选举出的Leader会增加Epoch，用以区分不同Leader管理集群的时期。

- Quorum
  - 表示集群中一个由大多数Follower节点所组成的集合，节点数目多于总结点数目的一半，在Leader选举以及Leader与Follower之间数据同步时，都需要经过一个Quorum中所有节点的通过才能进行下一步操作。

- Proposal
  - 提案，当Leader节点收到一个写请求时，先生成一个事务，然后会产生一个提案，将这个提案广播给所有Follower节点，等待Follower节点的ACK回应。提案包括这个事务的所有信息。

- Commit
  - 往本地数据库里提交请求，修改数据库中的数据。当Leader发送的Proposal消息得到大多数Follower返回的ACK信息之后，Leader就向所有Follower节点发送Commit消息，要求各个Follower节点修改本地数据库，与Leader节点的数据库保持一致。

PDB系统中节点状态切换策略

- PDB系统中的节点共有3种状态：
  - Looking：表示系统正在进行Leader选举，发生在系统刚启动或老Leader崩溃选举新Leader过程中；
  - Following：表示Follower节点所处的状态，Follower与Leader处于数据同步状态；
  - Leading：表示Leader节点所处的状态，当前集群中有且仅有一个Leader为主进程；

节点状态切换图

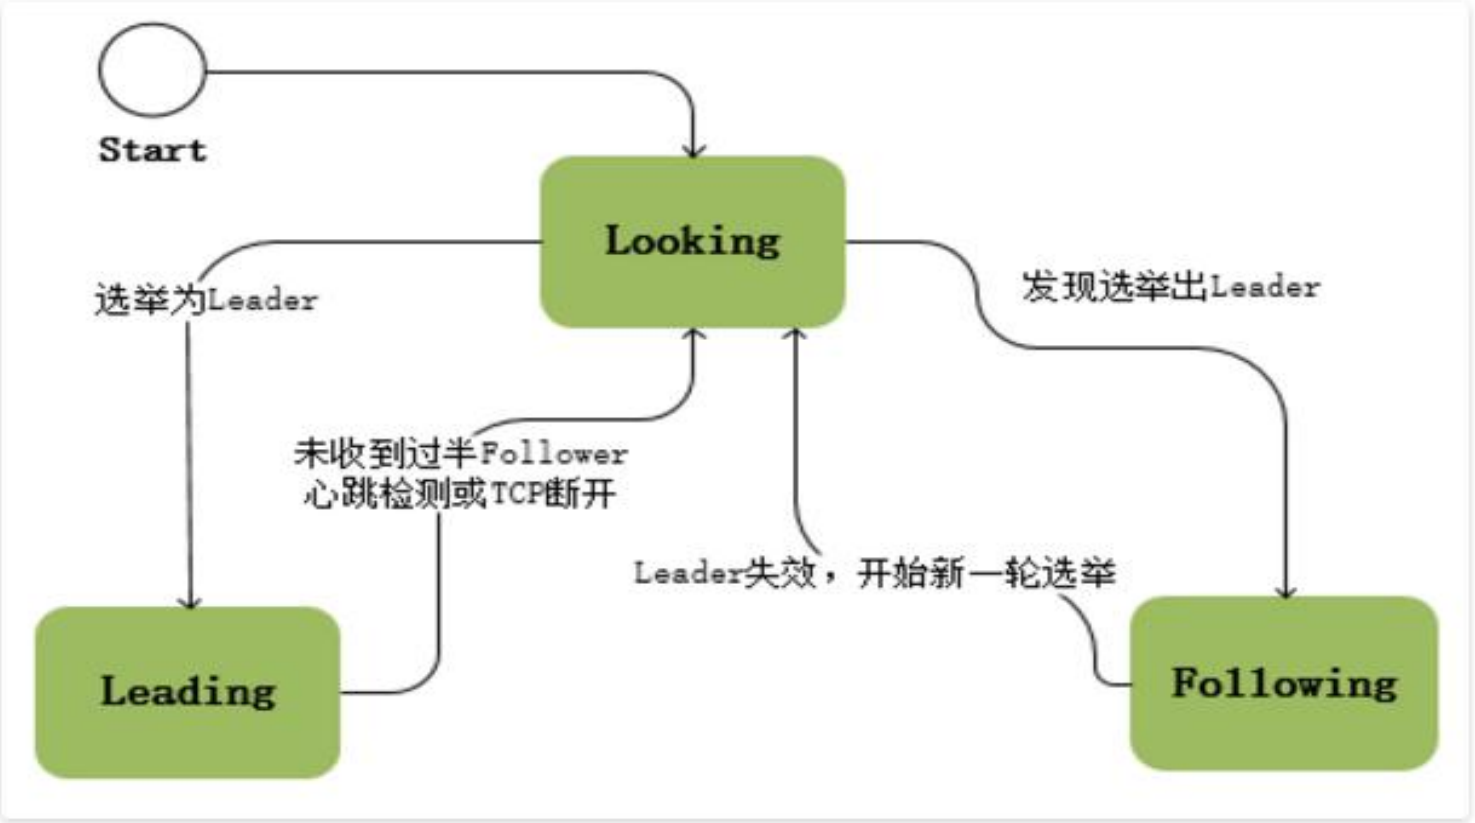

状态切换图

- 网络拓扑结构
  - 在Leader选举完成之后，Leader与所有Follower建立连接，系统网络呈星型网络拓扑结构

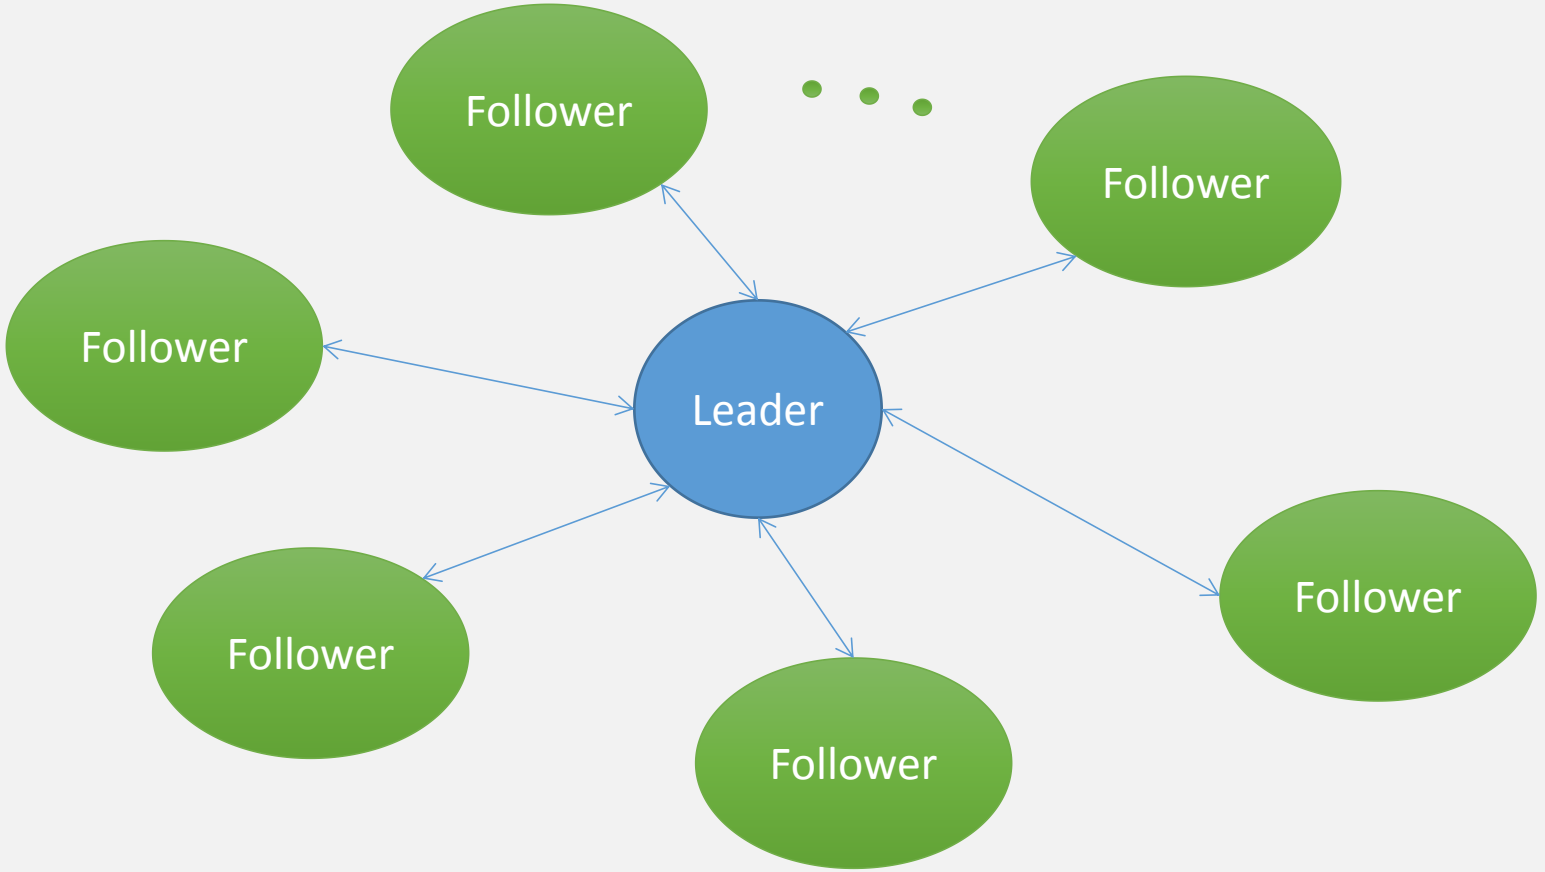

PDB集群数据同步过程

- 定义
  - 集群中的Follower节点同步Leader节点的数据库，与Leader节点的数据保持一致。同步方向严格限制为 Leader到Follower。
- 目的
  - 使集群中所有节点维护的本地数据库保持一致，对外提供高可用、容灾、容错的服务。
- 同步方式
  - 事务日志
    - ①如果Leader节点的事务日志更新，则根据Leader本地保存的事务日志同步Follower的数据库；（DIFF）
    - ②如果Follower节点的事务日志比Leader节点的日志更新，则Follower节点需要截断本地保存的事务日志，对本地数据库的操作做回滚；(TRUNC)
  - 快照
    - 如果Follower节点本地保存的事务日志太旧，则直接用Leader节点的数据库快照同步数据库；（SNAP）

- 数据同步分四个阶段：
  - Phase0：Leader选举
  - Phase1：发现(Discovery)
  - Phase2：数据同步(Synchronization)
  - Phase3：广播(Broadcast)

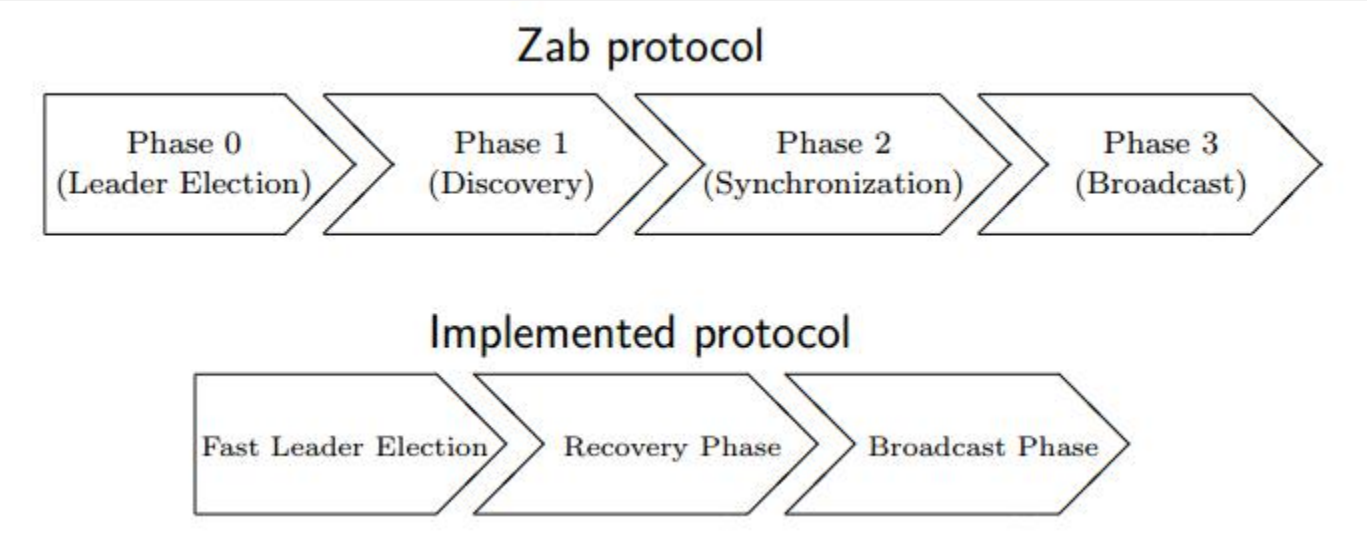

第一阶段(Discovery)交互时序图

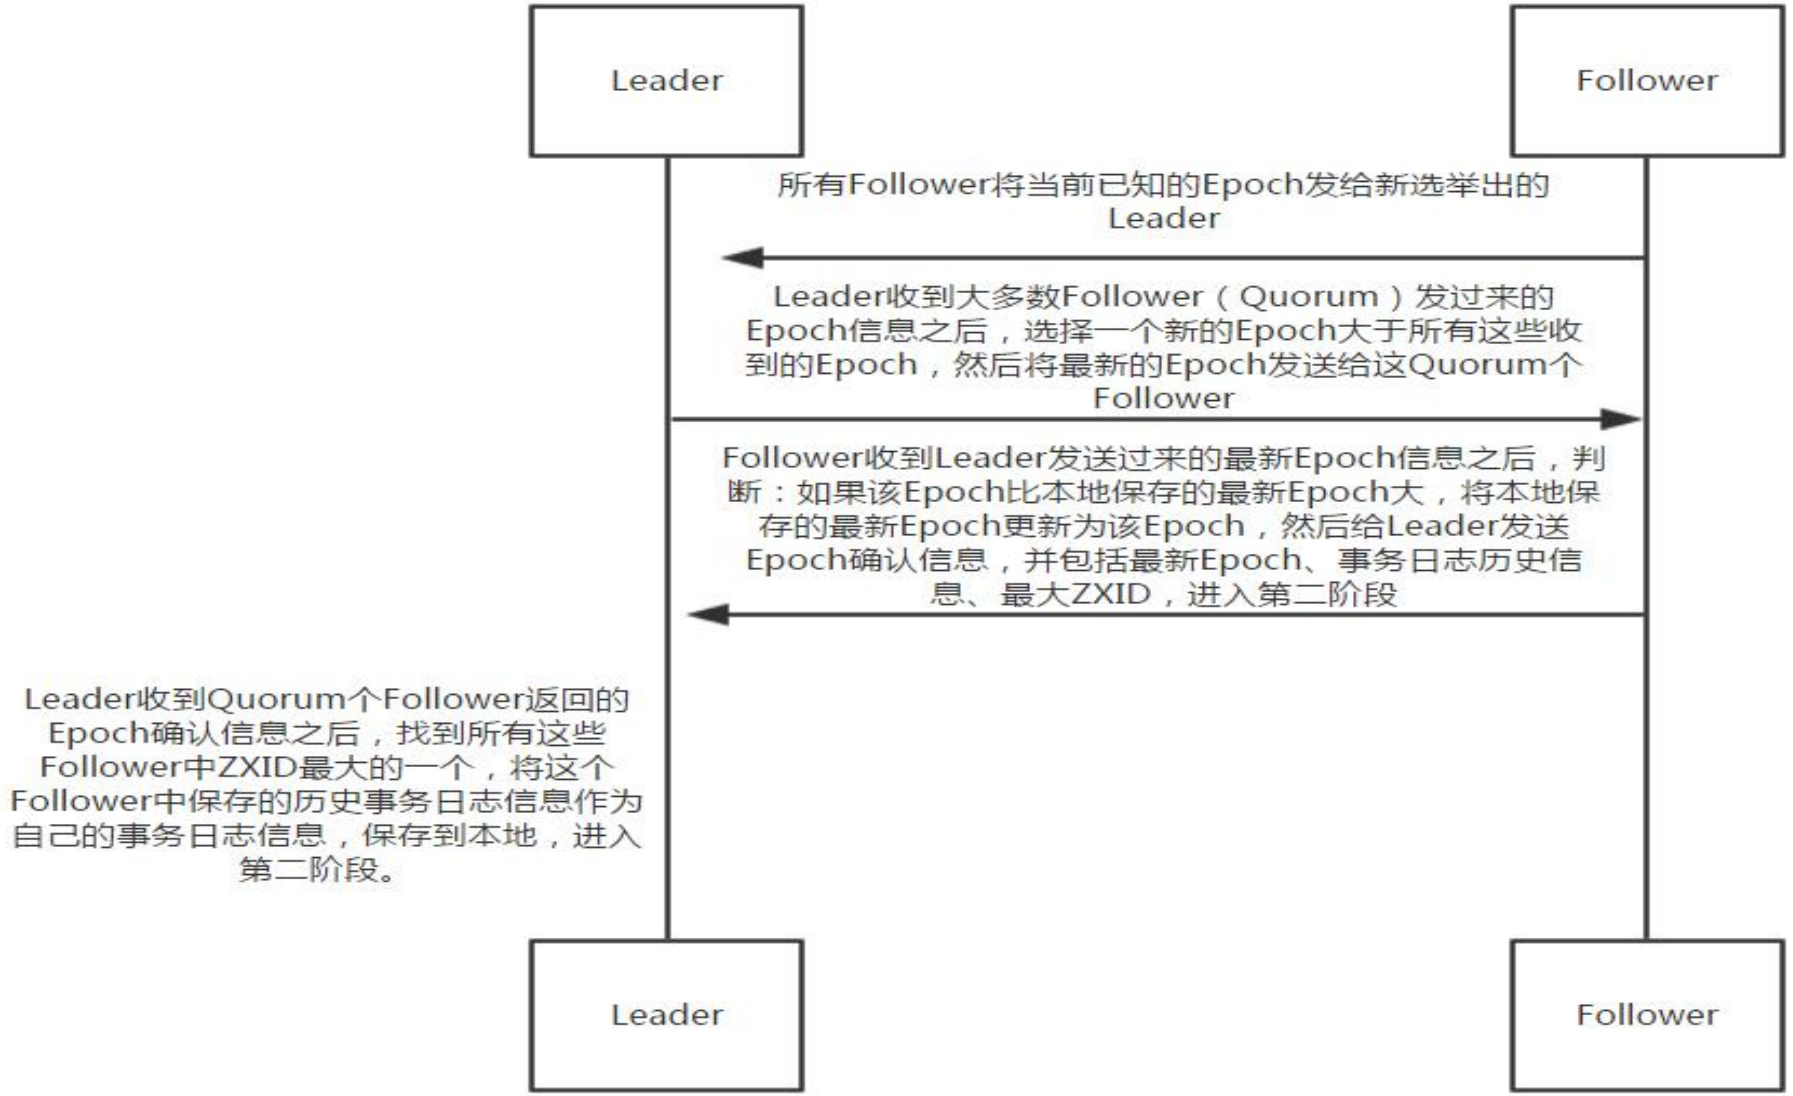

第二阶段(synchronization)交互时序图

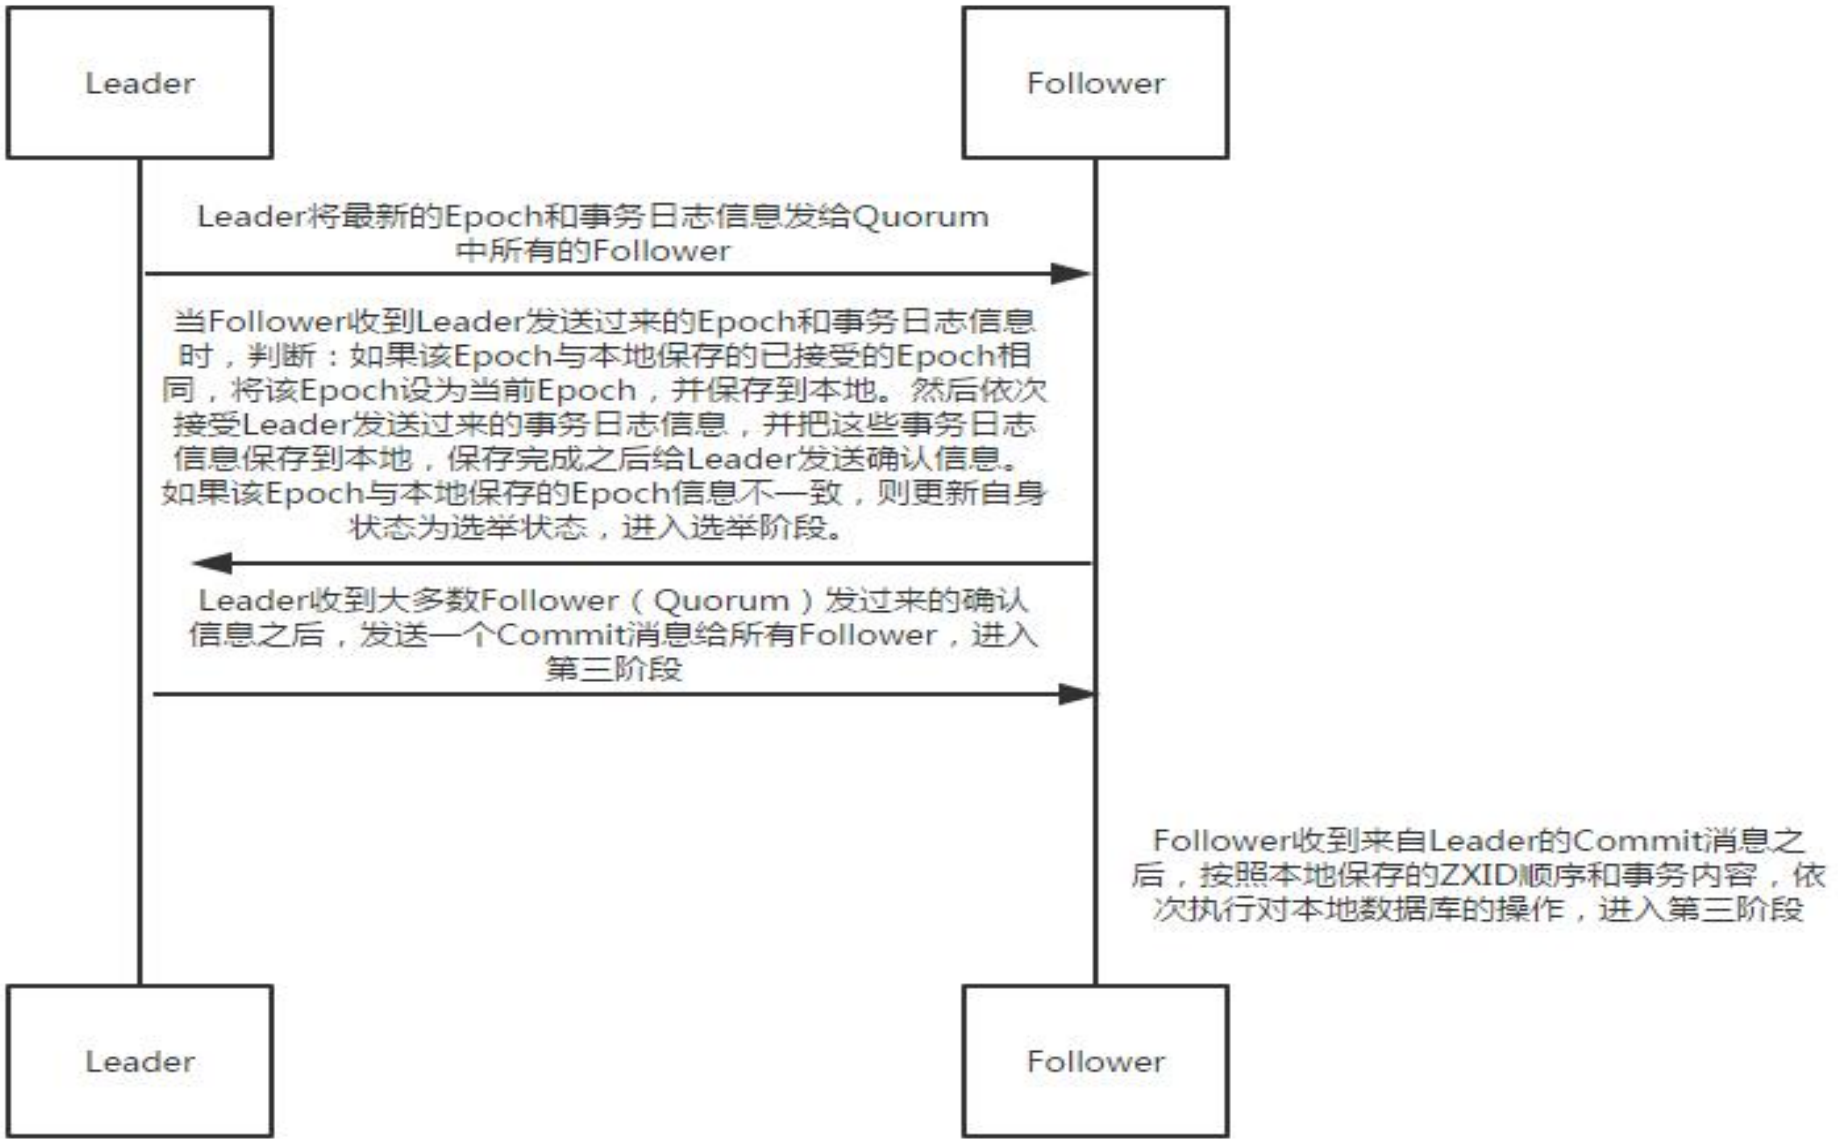

第三阶段(Broadcast)交互时序图

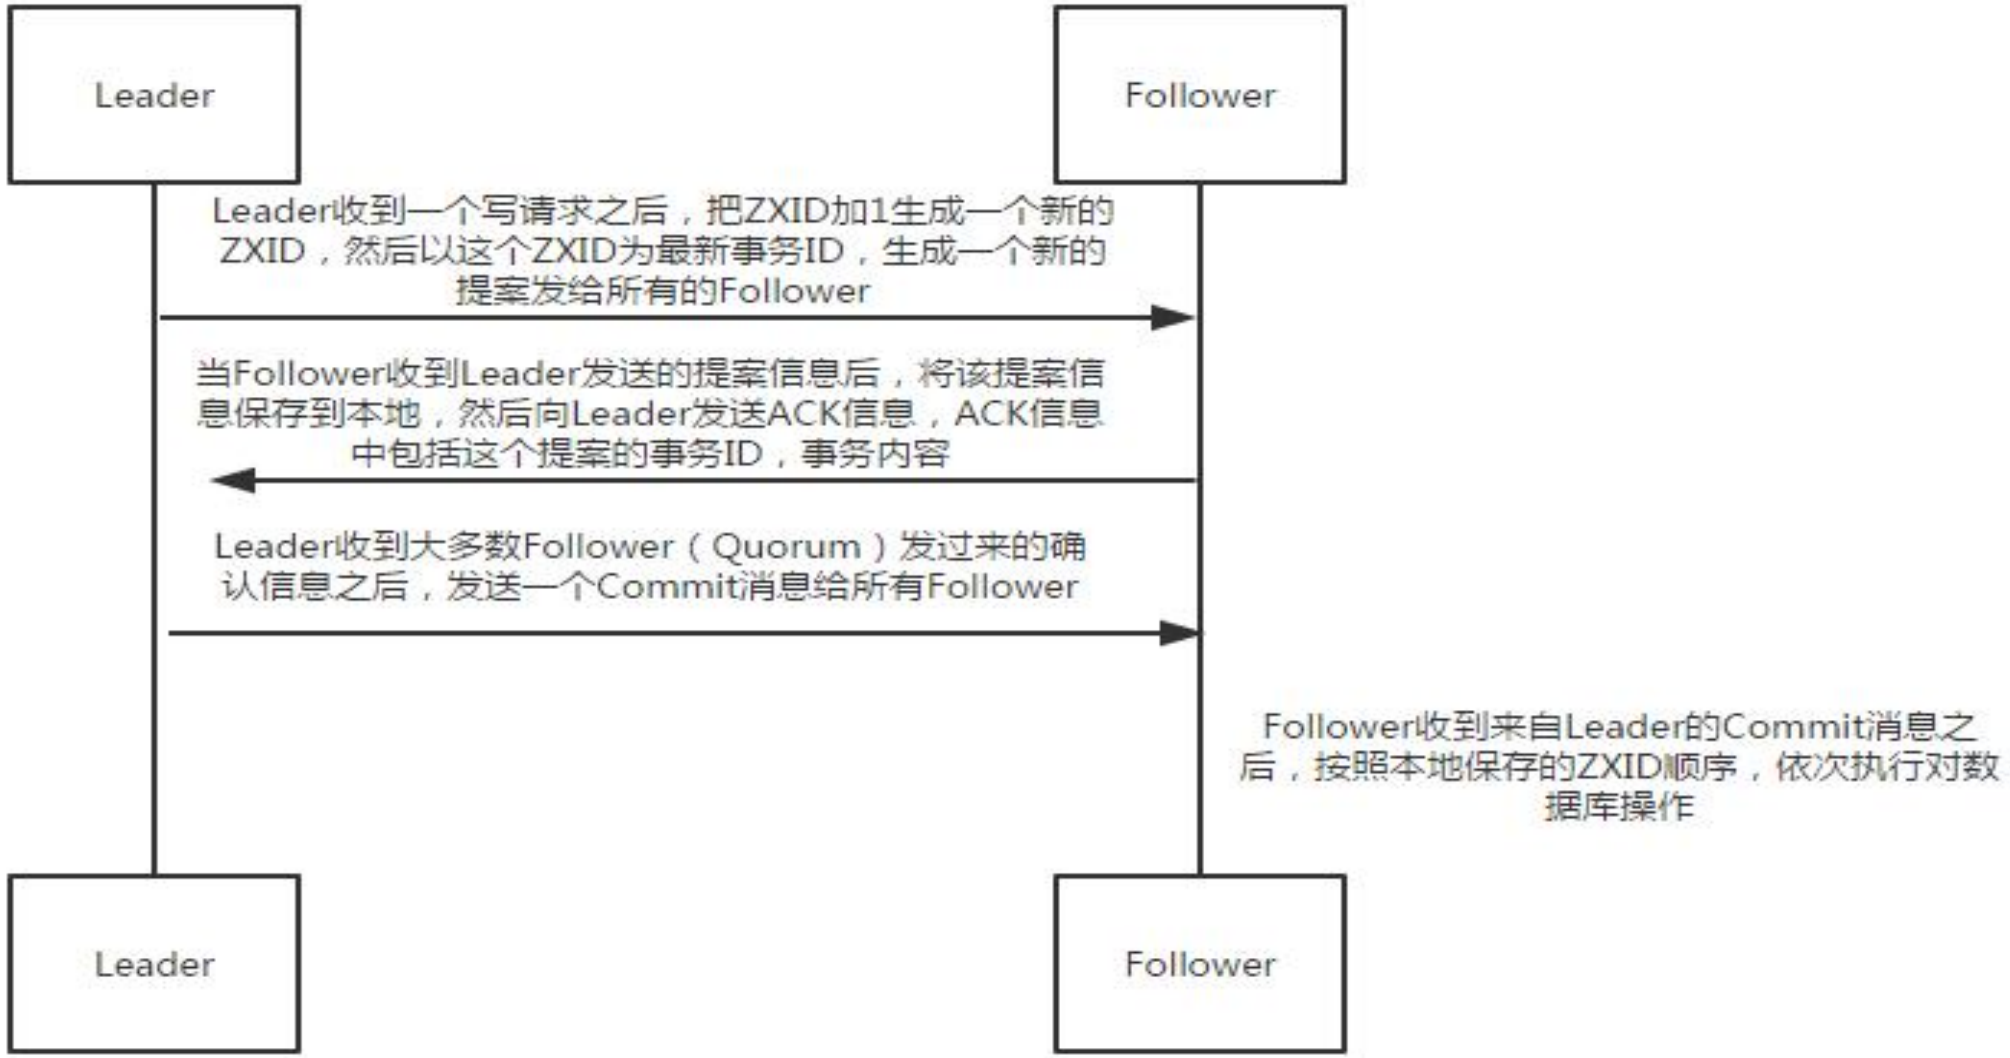

第四阶段交互时序图(与选举算法FLE强相关)

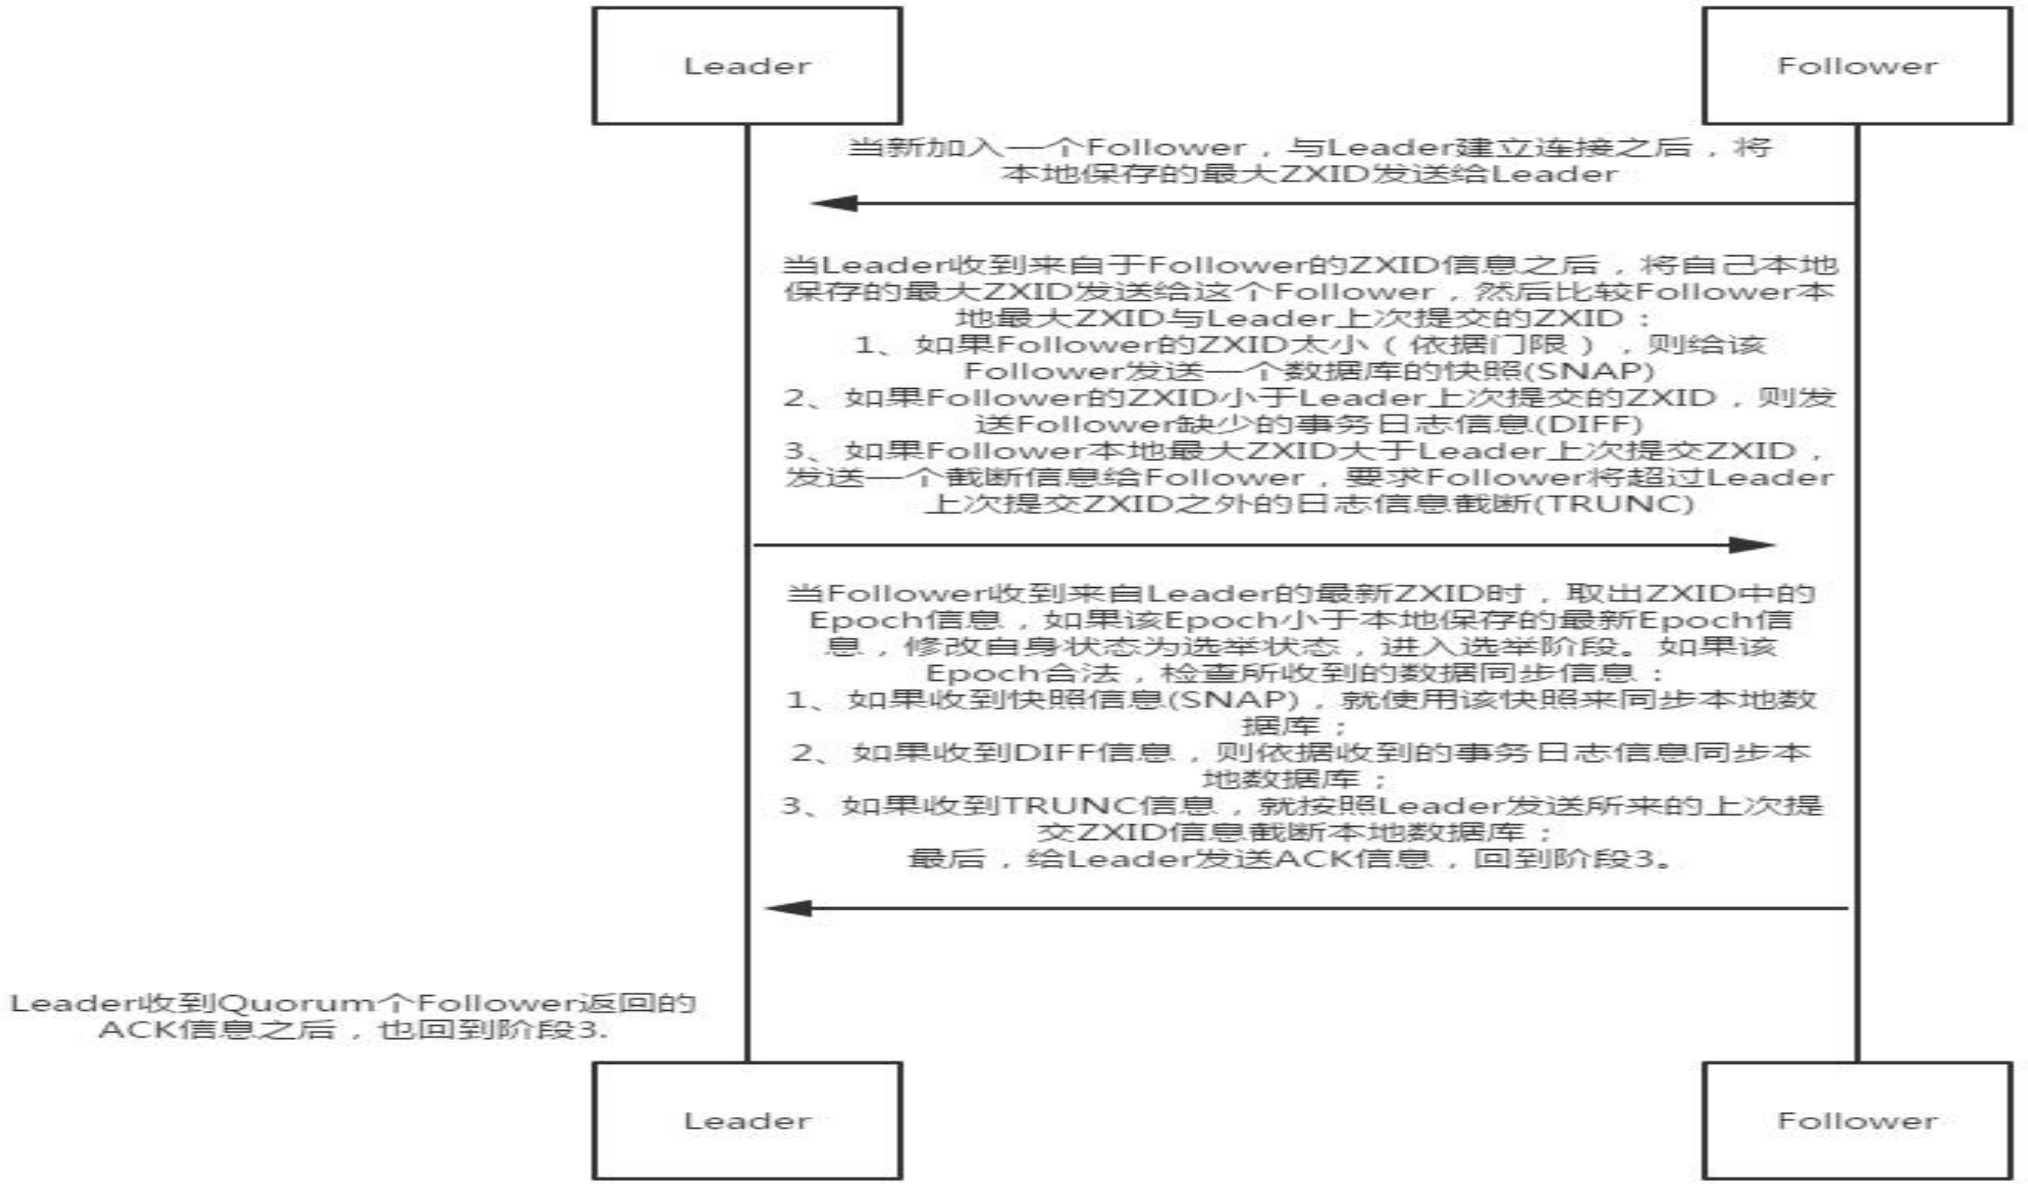

读写请求响应方式

- 读请求
  - 读请求直接有接收请求的节点响应，无论该节点是Leader还是Follower；
- 写请求
  - 写请求涉及到对数据库的修改和集群数据同步的过程，只能由Leader节点来处理。如果接收到写请求的是Follower节点，则该节点必须将该请求转发给Leader节点来处理。多个写请求按照到来的先后顺序放入队列(FIFO)，依次处理。

读写请求响应示意图

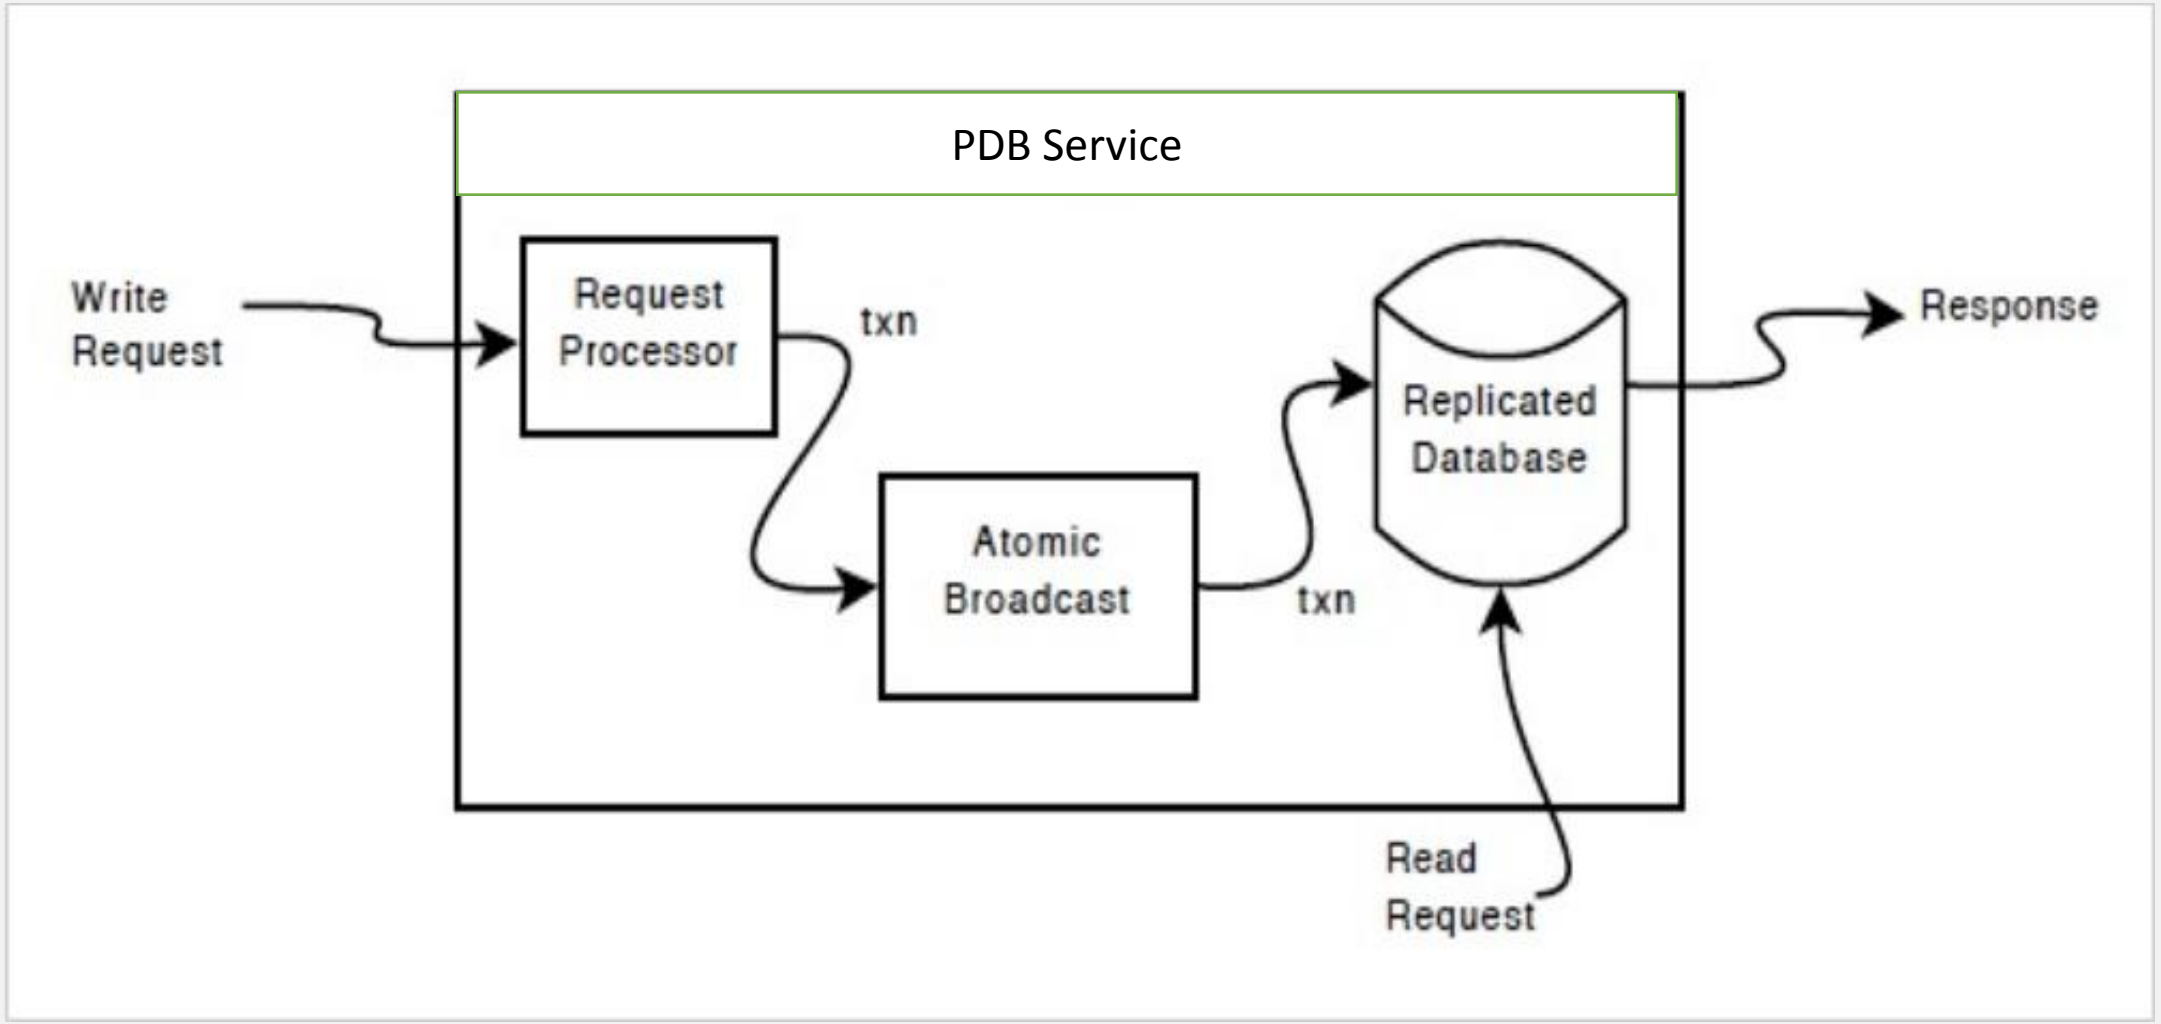

写请求处理流程

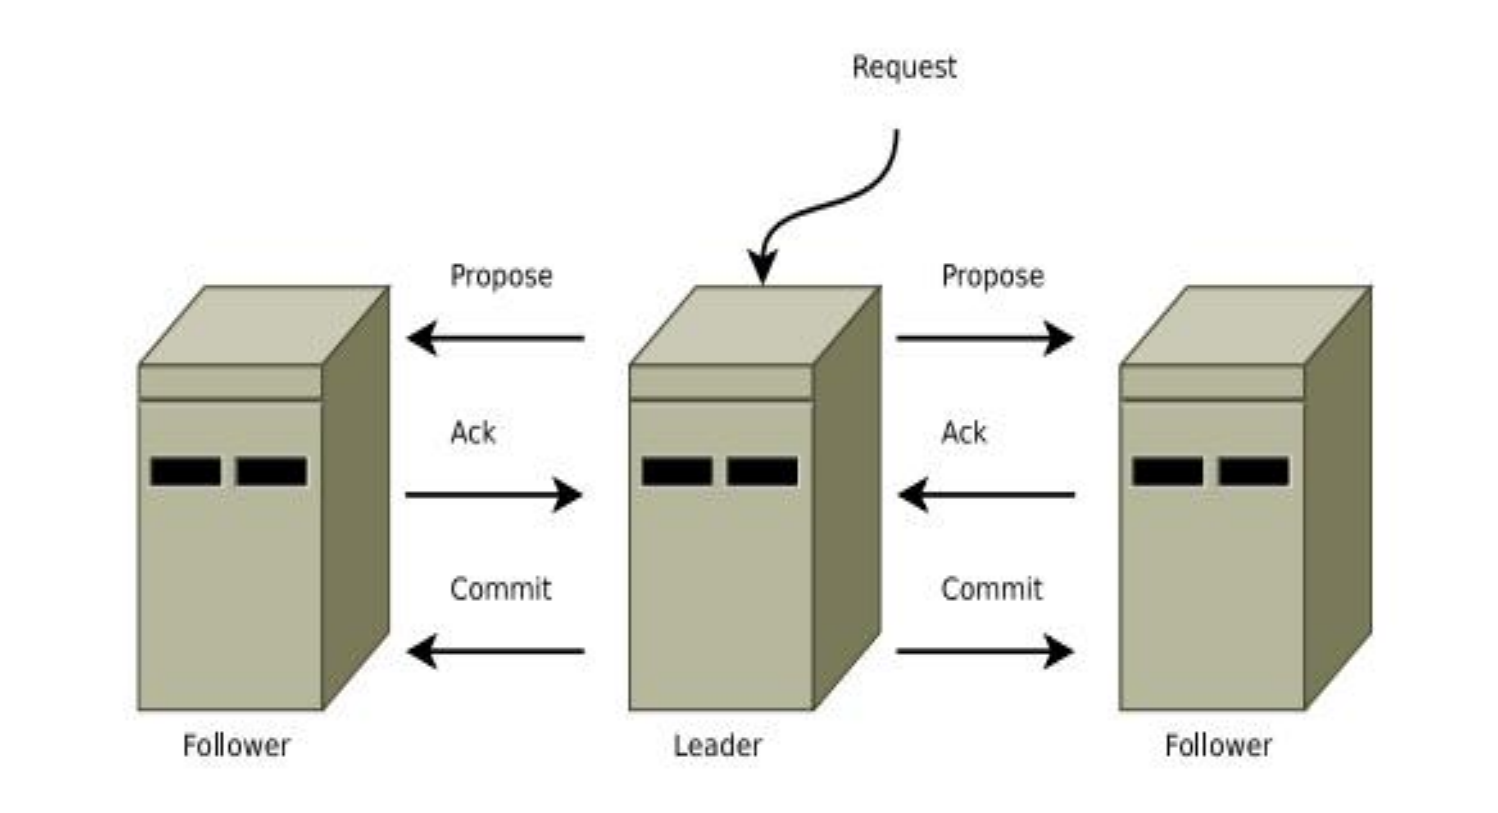

- 关键数据结构设计
  - epoch ywb_uint32_t 无符号32位整型变量，从0开始递增，每次发生Leader选举之后，新Leader会把上次的epoch加一生成新的epoch；
  - ZXID（ZooKeeper Transaction ID） ywb_uint64_t 无符号64位整型变量，表示事务ID，高32位标识epoch，低32位是一个计数器，表示在这个epoch内的事务编号，计数器的初始值也设置为0，每次生成新的事务ID时把计数器的值加一，发生Leader选举后，新Leader把计数器清零重新开始计数；
  - sid(server ID) yfs_sid_t server ID，用以标识集群中各个节点的ID，每个节点拥有全局唯一的server ID，将所有节点的server ID 保存在一个std::set容器中，在Leader节点广播请求时依据sid 对集群中的所有节点发送消息；
  - t_PaxosReqQue mWaitingQueue 请求等待队列，当Leader收到写请求后，就把这个请求放入这个等待队列，然后按照事务ID依次处理所有收到的请求；

具体代码实现介绍

- 关键数据结构（类）设计

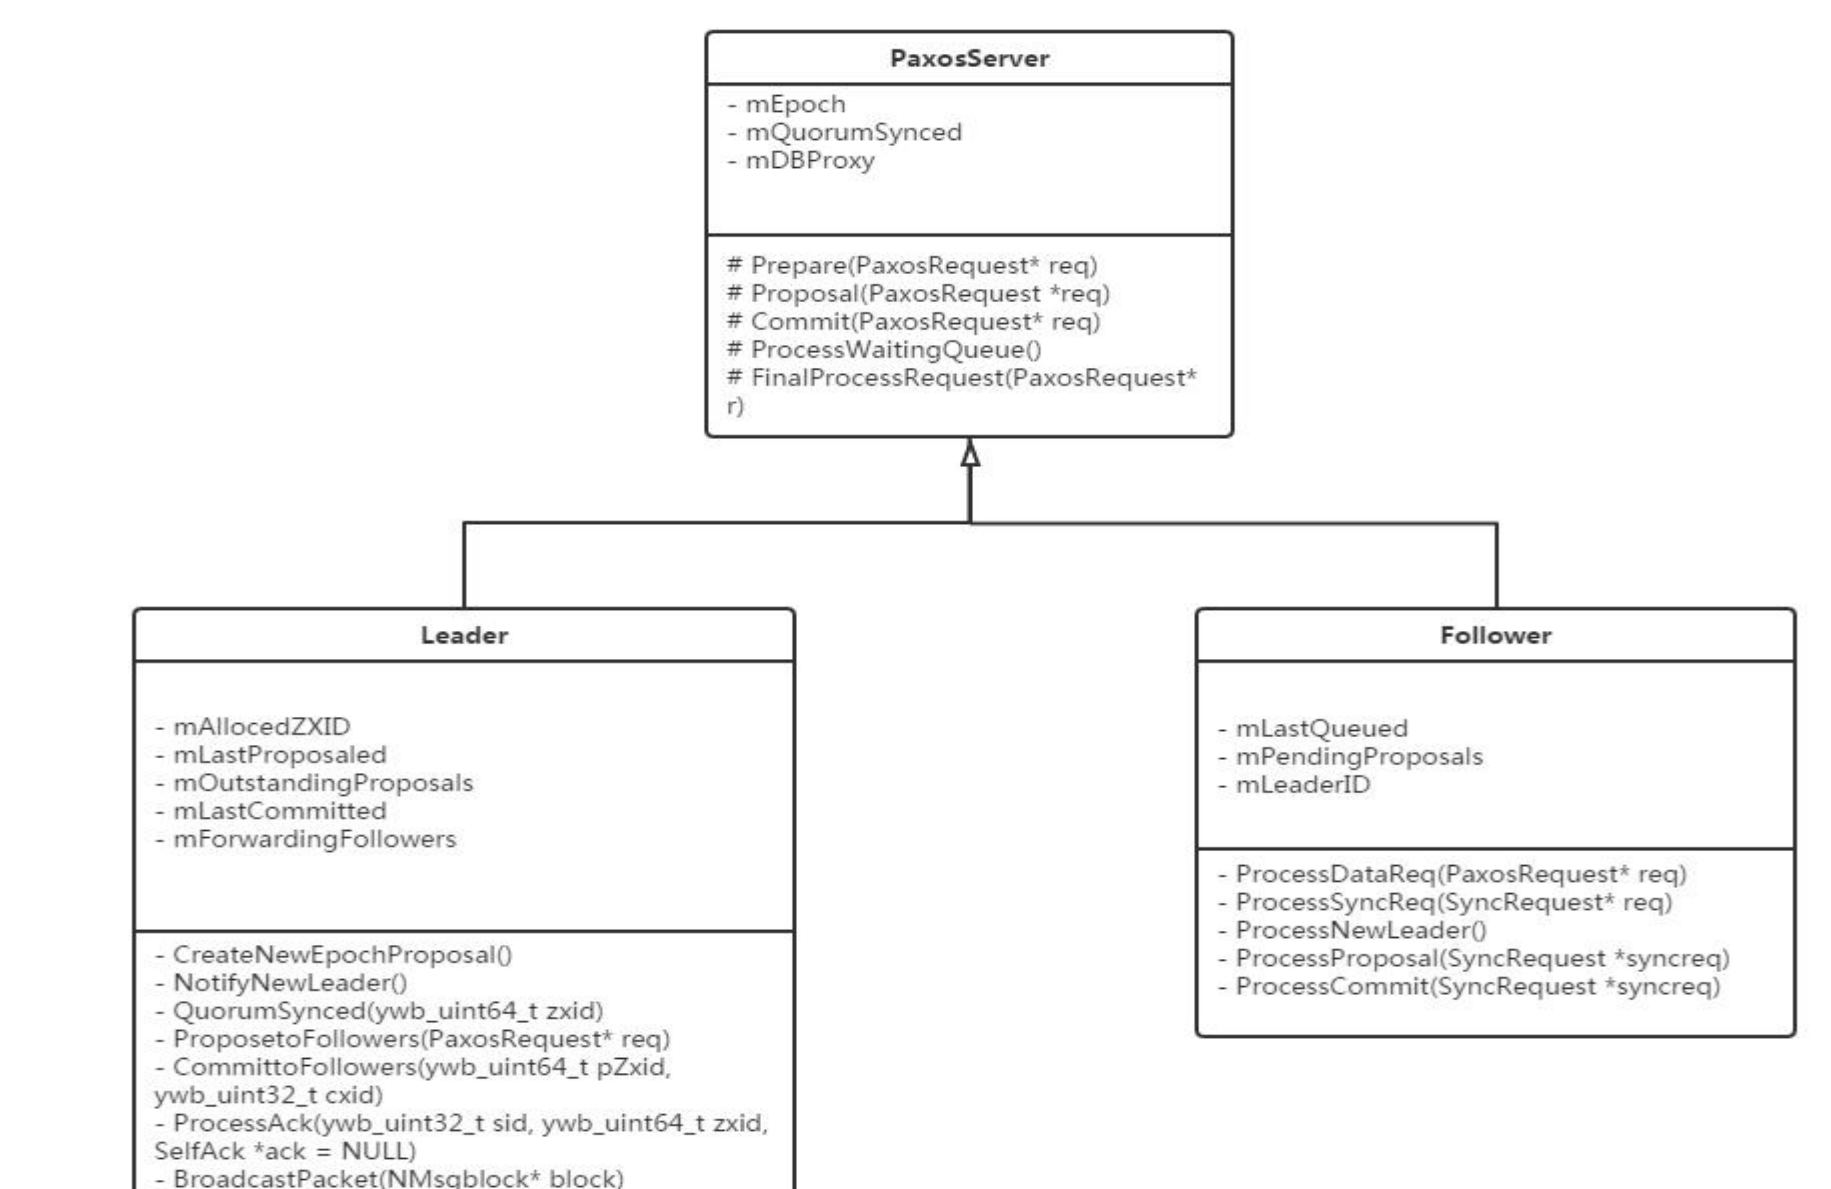

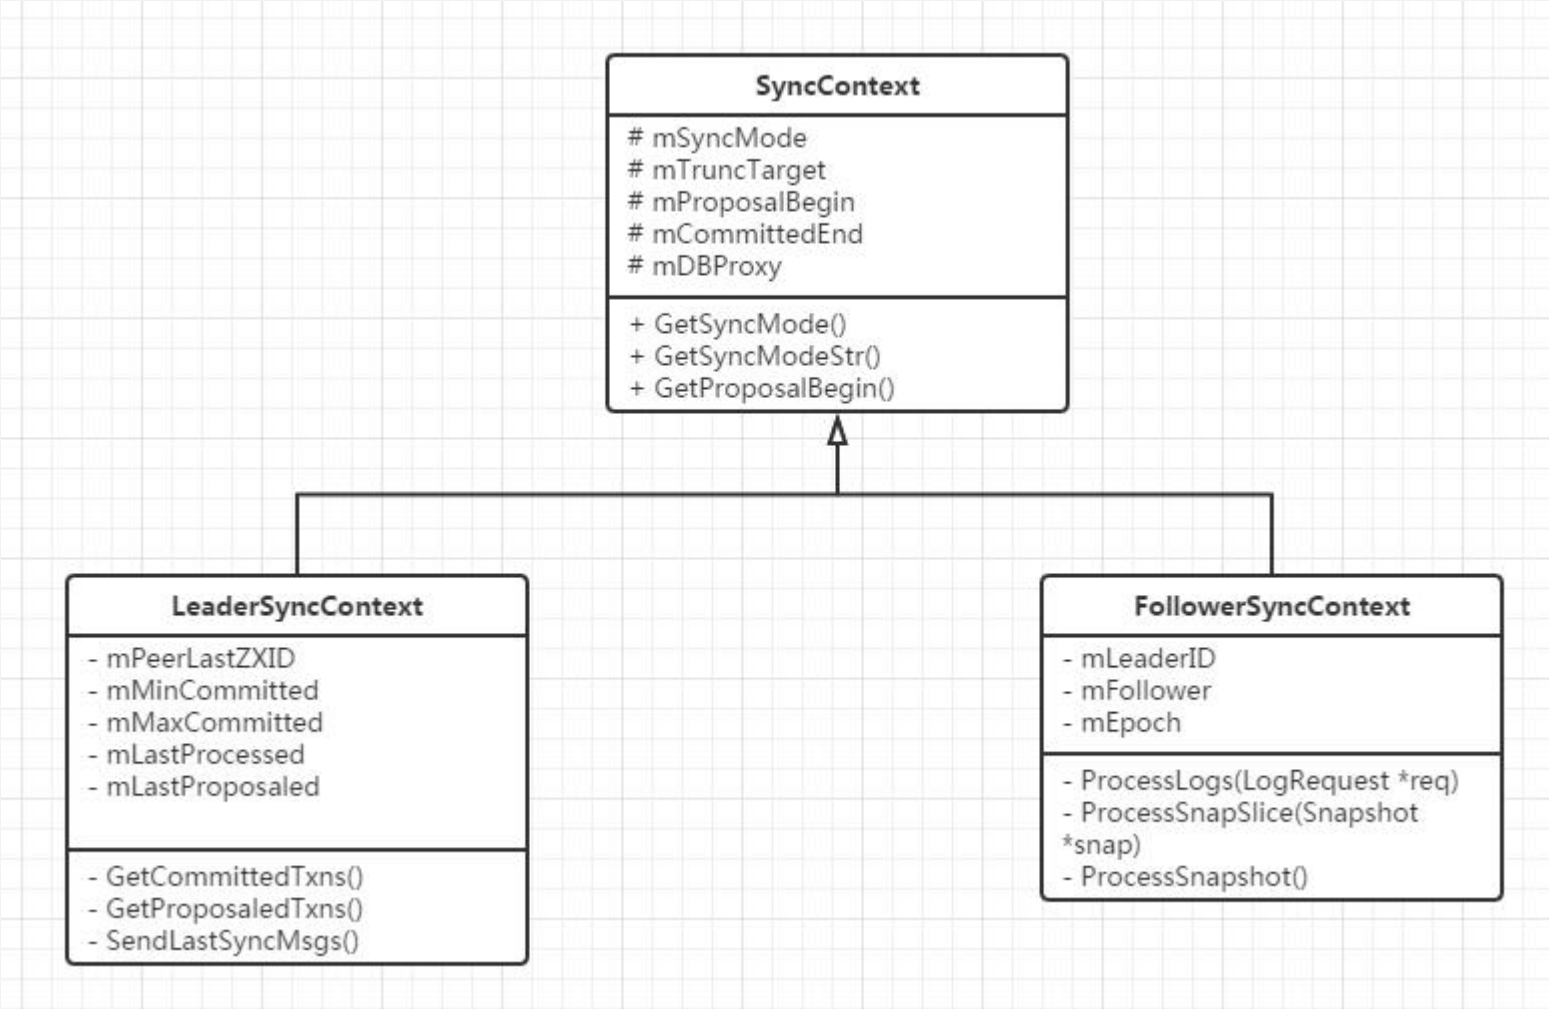

PDB数据库设计与实现

DAOWOO 达沃时代

- Shard数据库概念
  - PDB是一个分布式数据库，每个节点保持着数据库的一个完整副本，通过数据多副本冗余来达到高可用、高可靠、容灾、容错。在PDB中，每个节点维护的数据库副本称为shard。
- 两种类型
  - Key/Value类型数据库
  - SQL类型数据库（使用SQLite实现）

数据库存储模型

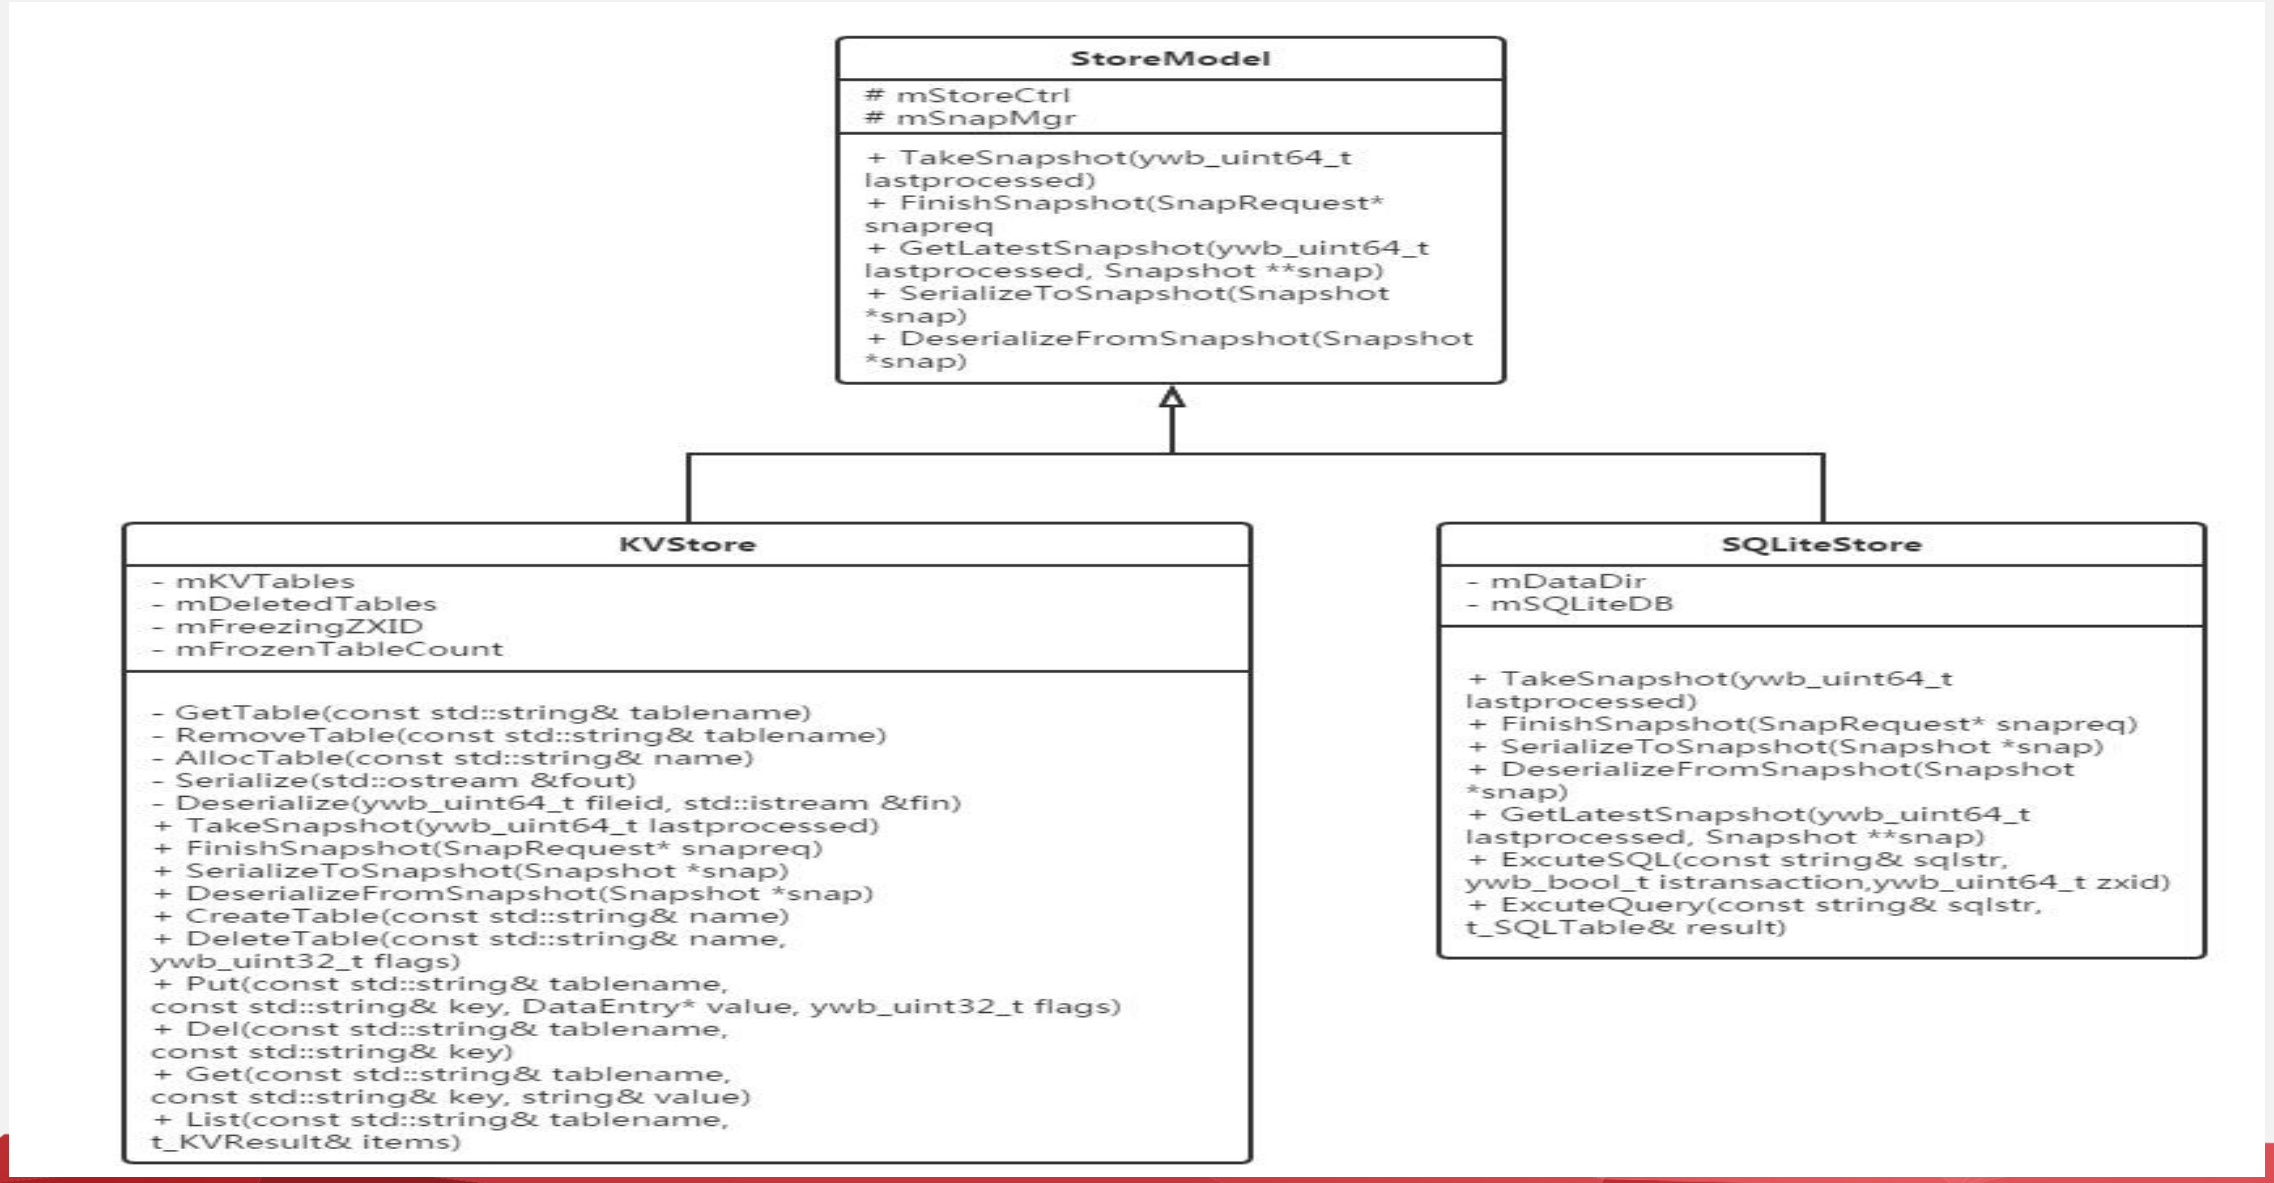

存储控制器

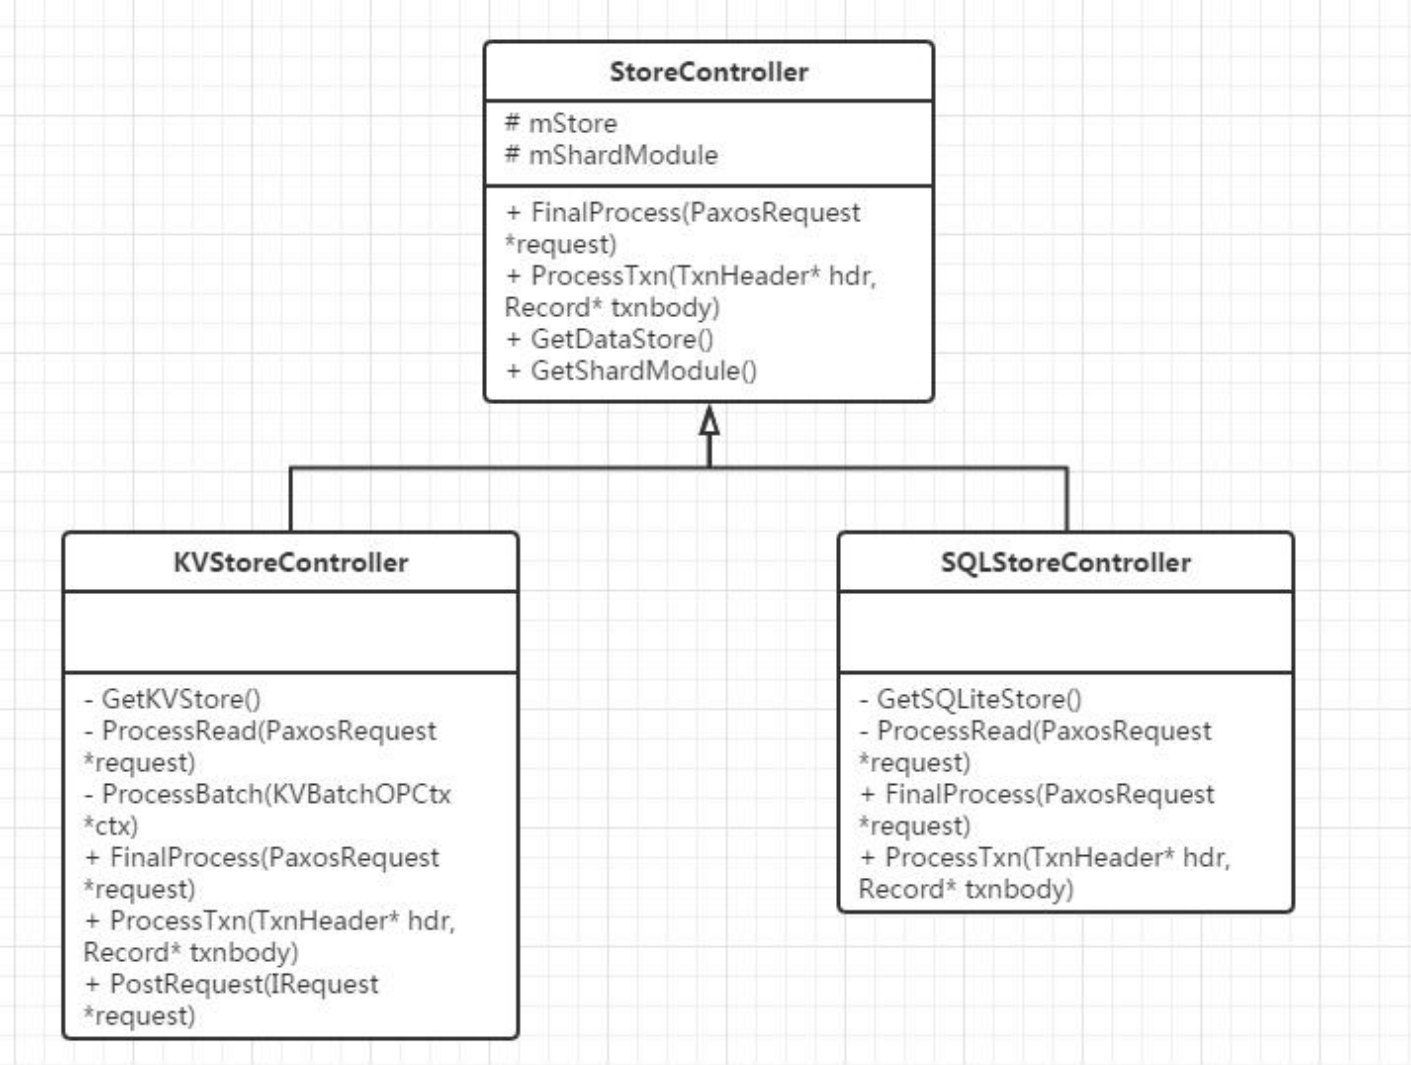

KV数据库分类

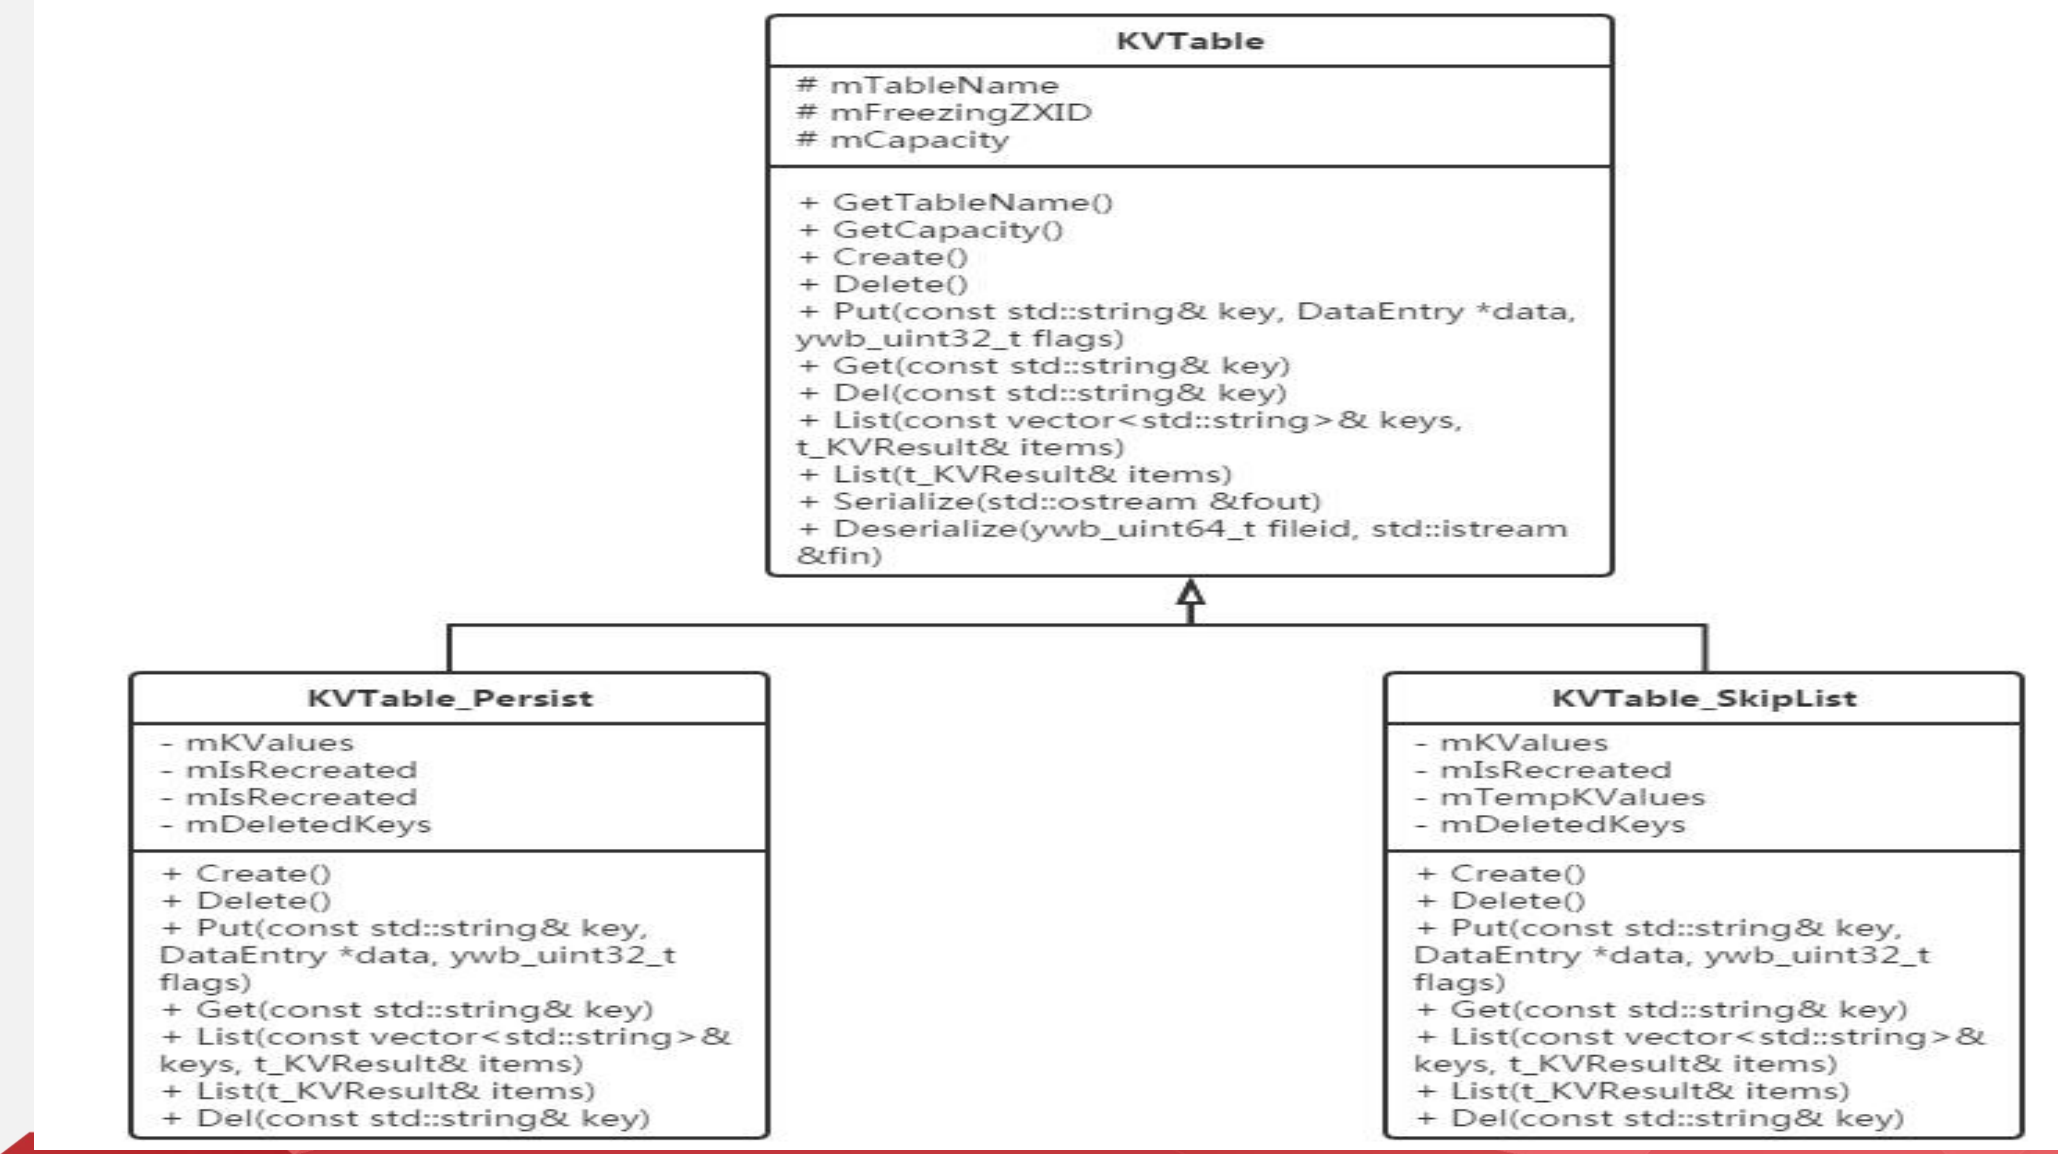

数据库操作类图

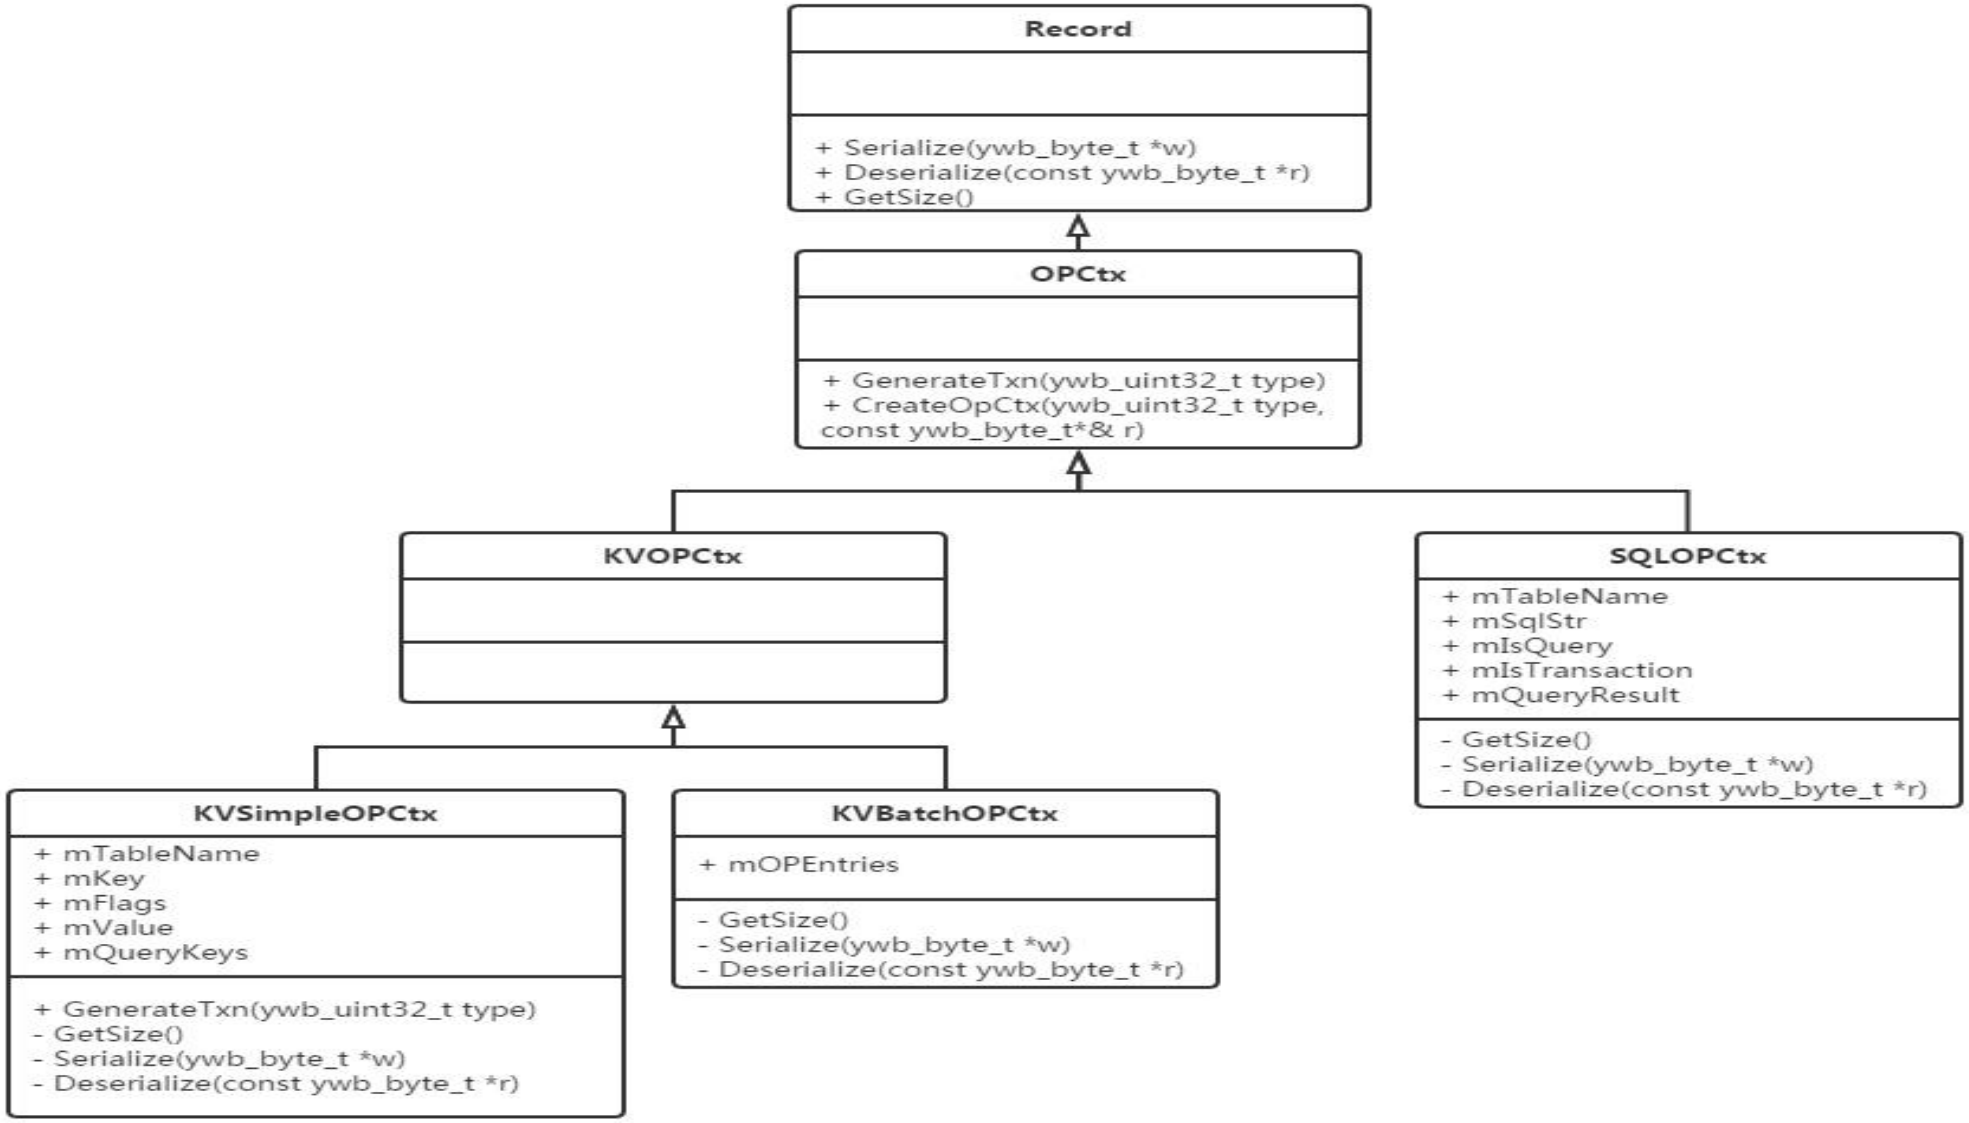

Thanks !

联系我们

北京总部
北京市朝阳区安定路一号国家奥林匹克体育中心体育场东南门2层2160室
邮编：100029
电话：+8610 8843 7583
传真：+8610 8437 6490

武汉分公司
武汉市洪山区珞瑜路33号中部创意大厦1907、1908
邮编：430074
电话：+8627 8786 2881
传真：+8627 8786 2567